

СЕМЕСТРОВАЯ ПРАКТИКА · ИТМО · ИЮНЬ 2026

DialogMTEB

Расширение набора диалоговых задач для оценки моделей векторных представлений текста на русский и французский языки

24

набора данных и задач в командном объеме

RU + FR

два направления перевода

открыто

код, настройки, проверки и
загруженные наборы данных

Кремнева Полина · Исаченко Богдан Руководитель: Леднева Дарья

Оценка моделей в диалогах пока разрознена

ГДЕ ЭТО ИСПОЛЬЗУЕТСЯ

- чат-боты и голосовые ассистенты
- поиск по истории обращений
- подбор и ранжирование ответов
- определение намерения пользователя

ЧЕГО НЕ ХВАТАЕТ

- общие наборы оценки слабо отражают диалоговую специфику
- в диалогах важны история, кореференция и неполные реплики
- русский и французский языки покрыты хуже английского
- разные модели часто сравниваются на несопоставимых данных

Нужен сопоставимый набор задач, который проверяет диалоговые модели на нескольких языках в одном протоколе.

DialogMTEB покрывает 5 типов диалоговых задач

Нужно забронировать
перелет в Лондон

Конечно, помогу
подобрать рейс.

НАМЕРЕНИЕ

Бронирование перелета

Пример: определить намерение по реплике
с учетом диалогового контекста.

01

Классификация

намерение, эмоция или другая метка
реплики

02

Парная классификация

совпадает ли смысл пары вопрос-
ответ

03

Ранжирование

упорядочить возможные ответы по
релевантности

04

Поиск

найти релевантный фрагмент диалога
или документ

05

Смысловая близость

оценить, насколько близки две реплики или два диалоговых фрагмента

Перевести набор задач, не нарушив его структуру

Можно ли расширить DialogMTEB на новые языки через автоматический перевод и контроль качества так, чтобы сохранить валидность задач?

ГИПОТЕЗА




Автоматический перевод, оценка языковой моделью и статические проверки позволяют получить пригодный многоязычный набор задач без ручной разметки с нуля.

ЧТО НЕЛЬЗЯ СЛОМАТЬ

- разбиения на выборки и число строк
- метки, идентификаторы и связи релевантности
- списки реплик и вложенные диалоги
- ссылки, имена файлов и служебный синтаксис

Работу разделили по языкам и зонам ответственности

УЧАСТНИК	ДОЛЯ	ЗОНА ОТВЕТСТВЕННОСТИ	ЧТО РАССКАЗЫВАЕТ НА ЗАЩИТЕ
Кремнева Полина	50%	перевод на русский; переводчик Yandex; оценка качества с помощью языковой модели	мотивация, типы задач, русские переводы, оценка качества
Исаченко Богдан	50%	перевод на французский; единая командная строка; настройки; проверки; выгрузка в Hugging Face	конвейер перевода, статический анализатор, исправленные ошибки, публикация результатов
Леднева Дарья	руководитель	научная постановка, методология DialogMTEB/MTEB, рецензирование результатов	методологический контекст проекта



В работе были разные типы диалоговых данных

НАМЕРЕНИЯ И КЛАССИФИКАЦИЯ

atis_intents · banking77 · vira-intent · CLINC150 · HWU64 ·
MTOPIntent · MASSIVE

ДИАЛОГОВЫЕ СЦЕНАРИИ

X-RiSAWOZ · Multi2WOZ · air-dialogue · FaithDial · DailyDialog

ПОИСК В ДИАЛОГАХ

statcan-dialogue-dataset-retrieval · WebLINX · CANARD ·
MANtIS · WoW · QReCC · TREC iKAT 2023 · Coral

ВОПРОСЫ-ОТВЕТЫ И СУММАРИЗАЦИЯ


ClarQA · TopiOCQA · Abg-CoQA · DialogSum

Командный пул: 24 набора данных и
задач в разных форматах DialogMTEB

Публикация: русские и французские
переводы лежат в организации
DeepPavlov

Цель: единый многоязычный протокол
оценки

Цепочка перевода и оценки качества



ЧТО ПЕРЕВОДИЛОСЬ

корпуса, вопросы, ответы, реплики и диалоговый контекст в разных типах задач DialogMTEV

ЧТО СОХРАНЯЛОСЬ

идентификаторы, разбиения, связи релевантности и формат входа для последующей оценки

КАК ПРОВЕРЯЛОСЬ

повторы запросов, выборочная проверка и оценка языковой моделью по трем критериям

Оценка языковой моделью: запрос и результат

ЗАПРОС К МОДЕЛИ

```
EVALUATION_PROMPT = """You are an expert linguist specializing in translation quality evaluation.

IMPORTANT: Evaluate each translation independently. Do not compare with previous examples.

Task:
Evaluate the given translation from {source_lang} to {target_lang} on a scale of 0 to 10.
Consider the **domain**: {domain} (e.g., banking, everyday conversation, sports, legal, medical, etc.).
The translation must be appropriate for this domain in terms of terminology and style.

Input:
- Source text ({source_lang}): "{source_text}"
- Translation ({target_lang}): "{translation}"

Scoring criteria (total 0-10):
1. **Accuracy & completeness** (0-4 points)
   - All key information is preserved.
   - No additions, omissions, or distortions.
   - **For idioms and cultural references**: prefer adaptive/idiomatic translation over literal word-for-word.
2. **Grammar & orthography** (0-3 points)
   - Correct grammar, spelling, punctuation.
   - No errors that hinder understanding.
3. **Naturalness & style** (0-3 points)
```

ПРИМЕР РЕЗУЛЬТАТА

	source	type	src_lang	tgt_lang	domain	original	
0	corpus	text	English	Russian	general	second major at the PGA Championship at Baltus...	второй
1	corpus	text	English	Russian	general	he earned the nickname "Captain Slow" owing to...	он заслу
2	corpus	text	English	Russian	general	"cannot participate in what I honestly believe...	"не могу у
3	corpus	text	English	Russian	general	August 1, 1942,	
4	corpus	text	English	Russian	general	"White", was released with "Perfect" as its co...	"White
5	queries	question	English	Russian	general	What did Khmer do?	
6	queries	question	English	Russian	general	How well did So Far Gone sell?	Наскол
7	queries	question	English	Russian	general	why did they take the hiatus?	
8	queries	question	English	Russian	general	what comic books does he appear in?	в каких

ВХОД

оригинал, перевод, язык и домен задачи

ШКАЛА

оценка от 0 до 10 для каждого примера


КРИТЕРИИ

смысл, грамматика, естественность диалога

ВЫХОД

балл и короткий комментарий о слабых местах

Единый конвейер уменьшил ручные ошибки



НАСТРОЙКИ

источник, поля, выборки и правила выгрузки описаны декларативно.

СТРАТЕГИИ

простые поля, списки реплик и вложенные структуры переводятся по-разному.

АВТОМАТИЗАЦИЯ

одна команда закрывает перевод, проверку, экспорт и загрузку.

Статический анализатор нашел ошибку, которую легко пропустить глазами

01

СИМПТОМ

В одном из вариантов DailyDialog переведенные реплики не соответствовали исходным строкам.

02

ПРОВЕРКА

`check-translation` сравнил структуру, число строк, списки реплик и подозрительно неизменные фрагменты.

03

ИСПРАВЛЕНИЕ

Мы пересобрали выгрузку из очищенного локального результата и убрали ложные предупреждения для ссылок, файлов и идентификаторов.

Практический эффект: перед загрузкой видно, где перевод действительно требует доработки, а где предупреждение является техническим шумом.

Переводы на русский и французский лежат в DeepPavlov

Hugging Face · организация DeepPavlov

командные переводы публикуются в одном месте: русские и французские версии помечаются суффиксами `_ru` и `_fr`, код и настройки лежат в открытых репозиториях

huggingface.co/DeepPavlov

НАМЕРЕНИЯ И КЛАССИФИКАЦИЯ

atis_intents · banking77 · vira-intent · CLINC150 · HWU64 ·
MTOPIntent · MASSIVE

ДИАЛоговые сценарии

X-RiSAWOZ · DailyDialog · FaithDial · Multi2WOZ · air-dialogue

Поиск и ранжирование

statcan-dialogue-dataset-retrieval · WebLINX · CANARD · MANTIS ·
WoW · QReCC · Coral · TREC iKAT 2023

Вопросы-ответы и суммаризация

ClarQA · TopiOCQA · Abg-CoQA · DialogSum

Риски понятны, следующий этап уже определен

ОГРАНИЧЕНИЯ

- автоматический перевод может менять прагматику и стиль диалога
- служебные поля нельзя переводить как обычный текст
- не все поля одинаково важны для итоговой оценки моделей
- оценку языковой модели нужно калибровать на ручной проверке

СЛЕДУЮЩИЕ ШАГИ

- дозавершить оставшиеся языковые версии MANTIS, WoW, Abg-CoQA и Coral
- добавить ручную двуязычную проверку на небольшой выборке
- запустить многоязычную оценку DialogMTEB
- расширить конвейер на новые языки

Мы не просто перевели наборы данных: мы подготовили воспроизводимую основу для многоязычной оценки диалоговых моделей.