

СЕМЕСТРОВАЯ ПРАКТИКА · ИТМО · ИЮНЬ 2026

DialogMTEB

Расширение диалогового benchmark для embedding-моделей на русский и французский языки

25

DialogMTEB tasks в общем scope

RU + FR

два языковых трека практики

open-source

GitHub, configs, checks, HF datasets

Кремнева Полина · Исаченко Богдан Руководитель: Леднева Дарья

Embeddings в диалогах: оценка пока фрагментирована

ГДЕ ЭТО ИСПОЛЬЗУЕТСЯ

- чат-боты и ассистенты
- поиск по истории поддержки
- retrieval и reranking ответов
- классификация интенгов и маршрутизация

ГДЕ ВОЗНИКАЕТ GAP

- МТЕВ шире, но не фокусируется на диалоговой специфике
- в диалогах важны история, кореференция и неполные реплики
- многоязычное покрытие диалоговых задач остается слабым
- разные модели сравниваются на несопоставимых данных

Нужен сопоставимый benchmark, который проверяет диалоговые embedding-модели на нескольких языках в одном протоколе.

DialogMTEB покрывает 5 типов диалоговых задач

Classification

I need to book a flight to London

Sure, let me help you with that.

Intent: Flight Booking 97%

Other intents 3%

✈️ 50 • 📋 14 • 🌐 7

EXAMPLE DATASETS

ATIS Intent

Booking77

пример: intent classification на диалоговой реплике

01

Классификация

intent, emotion, class label

02

Парная классификация

match / no match для пары реплик

03

Ранжирование

релевантность кандидатов ответа

04

Поиск

query → dialogue passage / document

05

Semantic similarity

насколько близки две реплики или диалоговые фрагменты

Перевести benchmark, не разрушив benchmark

Можно ли расширить DialogMTEB на новые языки через автоматический перевод и контроль качества так, чтобы сохранить валидность задач?

ГИПОТЕЗА

Автоматический перевод с LLM-контролем и структурными sanity checks позволяет получить пригодный multilingual benchmark без ручной разметки с нуля.

ЧТО НЕЛЬЗЯ СЛОМАТЬ

- split'ы и число строк
- labels, ids, qrels
- диалоговые turns и списки реплик
- URLs, filenames, action syntax

Распределение задач было 50/50 по языковым трекам

УЧАСТНИК	ДОЛЯ	ЗОНА ОТВЕТСТВЕННОСТИ	ЧТО РАССКАЗЫВАЕТ НА ЗАЩИТЕ
Кремнева Полина	50%	Russian track: перевод EN → RU, notebook-based workflow, Yandex Translator, LLM-as-a-judge	мотивация, типы задач, RU-переводы, LLM-оценка
Исаченко Богдан	50%	French track: CLI/pipeline, YAML configs, translation strategies, validation, parquet export, HF upload	pipeline, проверки, ошибки, HF artifacts, воспроизводимость
Леднева Дарья	руководитель	научная постановка, методология DialogMTEB/MTEB, рецензирование результатов	методологический контекст проекта

Scope: 25 задач и 24 named dataset families

INTENT / CLASSIFICATION

atis_intents · banking77 · vira-intent · CLINC150 · HWU64 ·
MTOPIntent · MASSIVE

TASK-ORIENTED DIALOGUE

X-RiSAWOZ · Multi2WOZ · air-dialogue · FaithDial · DailyDialog

CONVERSATIONAL RETRIEVAL

statcan-dialogue-dataset-retrieval · WebLINX · CANARD ·
MANtIS · WoW · QReCC · TREC iKAT 2023 · Coral

QA / SUMMARIZATION

ClarQA · TopiOCQA · Abg-CoQA · DialogSum

RU: notebook translation + LLM
evaluation

FR: 8 datasets uploaded, 4 in progress

Goal: единый multilingual evaluation
protocol

Быстрые notebook-пайплайны + LLM-оценка качества

PIPELINE

dataset



Yandex Translator



cache + retries



LLM judge



MTEB format

Accuracy &
completeness

Grammar &
orthography

Naturalness &
style

Ценность: быстро переводить отдельные датасеты, проверять качество и готовить RU artifacts для оценки моделей.

Datasets: DeepPavlov, **canard_ru** 0 Following DeepPavlov 125

Modalities: Text Formats: parquet optimized-parquet Size: 10K - 100K Libraries: Datasets pandas

Dataset card Data Studio Files and versions xet Community Settings

Dataset Viewer Auto-converted to Parquet API Embed Duplicate Data Studio

Subset (3) corpus · 25.8k rows Split (3) train · 20.2k rows

Search this dataset

text string	text_ru string	id string
33,015,420 spoke the standard dialects, 19 643...	33 015 420 человек говорили на стандартных диалектах, 19 643...	d_train_C_69758fcdcf1f46baba0e92c0f3b0919c_1_q#1
World Malayalee Council, the organisation working...	Всемирный совет малайцев, организация, работающая с...	d_train_C_69758fcdcf1f46baba0e92c0f3b0919c_1_q#2
In 2010, the Census of Population of Singapore...	В 2010 году перепись населения Сингапура показала, что в...	d_train_C_69758fcdcf1f46baba0e92c0f3b0919c_1_q#5
Malayalam is derived from old Tamil and Sanskrit in...	Малаялам произошел от древнетамильского и санскрита...	d_train_C_69758fcdcf1f46baba0e92c0f3b0919c_0_q#1
Malayalam literature is ancient in origin. The...	Литература на малаяламе имеет древнее происхождение...	d_train_C_69758fcdcf1f46baba0e92c0f3b0919c_0_q#2
The oldest literature works in Malayalam, distinct fro...	Древнейшие литературные произведения на малаяламе,...	d_train_C_69758fcdcf1f46baba0e92c0f3b0919c_0_q#3
Madhava Panikkar, Sankara Panikkar and Pan...	Мадхава Паниккар, Шанкара Паниккар и Пан...	d_train_C_69758fcdcf1f46baba0e92c0f3b0919c_0_q#4

Previous 1 2 3 ... 202 Next

LLM проверяет смысл, грамматику и естественность перевода

ЧТО ОЦЕНИВАЕТСЯ

- сохранен ли смысл исходной реплики
- нет ли добавлений, пропусков и искажений
- грамматически ли корректен перевод
- звучит ли реплика естественно для диалога

Выход: score 0-10 + текстовое объяснение, которое помогает находить слабые места перевода.

```
EVALUATION_PROMPT = """You are an expert linguist specializing in translation quality evaluation.


IMPORTANT: Evaluate each translation independently. Do not compare with previous examples.

Task:
Evaluate the given translation from {source_lang} to {target_lang} on a scale of 0 to 10.
Consider the **domain**: {domain} (e.g., banking, everyday conversation, sports, legal, medical, etc.).
The translation must be appropriate for this domain in terms of terminology and style.

Input:
- Source text ({source_lang}): "{source_text}"
- Translation ({target_lang}): "{translation}"

Scoring criteria (total 0-10):
1. **Accuracy & completeness** (0-4 points)
  - All key information is preserved.
  - No additions, omissions, or distortions.
  - **For idioms and cultural references**: prefer adaptive/idiomatic translation over literal word-for-word.
2. **Grammar & orthography** (0-3 points)
  - Correct grammar, spelling, punctuation.
  - No errors that hinder understanding.
3. **Naturalness & style** (0-3 points)
```

Унифицированный CLI превращает перевод в воспроизводимый pipeline



CONFIGS

dataset schema, source, fields, splits и upload layout описаны декларативно.

STRATEGIES

разные структуры переводятся разными стратегиями, включая вложенный `deep\_map`.

AUTOMATION

CLI закрывает перевод, проверку, parquet export и загрузку в HF org.

Структурные проверки ловят ошибки, которые LLM может не заметить

split / row count mismatch

пустые переводы

разные длины списков

подозрительно
неизмененный английский

WebLINX action sequence drift

DailyDialog row misalignment

ВАЖНО ДЛЯ PRECISION

Checker отдельно suppress'ит ложные warnings для URLs, filenames, paths, emails, attachments и hash/id-like values.

ПРАКТИЧЕСКИЙ ЭФФЕКТ

Перед загрузкой видно, где перевод реально требует ручной доработки, а где warning был техническим шумом.

Переводы опубликованы как проверяемые open-source артефакты

FRENCH DATASET	ROWS	STATUS
air_dialog_fr	402037	uploaded
daily_dialog_fr	102979	uploaded
canard_fr	77250	uploaded
multiwoz_fr	71410	uploaded
clarqa_fr	34390	uploaded
weblinx_fr	19657	uploaded
statcan_dialog_fr	11358	uploaded
faithdial_fr	3539	uploaded*

RU ARTIFACTS

[interpparietes/DialogMTEB](#)

notebooks, Yandex translation, LLM evaluation

FR ARTIFACTS

[IsachenkoBogdan/data-translate](#)

CLI, configs, checks, upload automation

* FaithDial artifact сейчас содержит `history\_fr` и `knowledge\_fr`. In progress: MANTIS · WoW · Abg-CoQA · Coral.

Риски понятны, поэтому pipeline проектировался вокруг проверок

ОГРАНИЧЕНИЯ

- автоматический перевод может менять прагматику и стиль диалога
- служебные поля нельзя переводить как обычный текст
- не все dataset fields одинаково важны для evaluation
- LLM judge требует калибровки на human audit

СЛЕДУЮЩИЕ ШАГИ

- дозавершить MANTIS, WoW, Abg-CoQA, Coral
- добавить in-domain bilingual human audit
- запустить multilingual DialogMTEB evaluation
- расширить pipeline на новые языки

Мы не просто перевели датасеты: мы подготовили воспроизводимую основу для многоязычной оценки диалоговых embedding-моделей.

Приложение

Как презентация закрывает критерии

Актуальность	dialogue embeddings нужны для ассистентов, retrieval и поиска по разговорам
Практическая значимость	публичные multilingual datasets, scripts, configs и HF artifacts
Новизна	расширение DialogMTEB на RU/FR с сохранением структуры задач
Impact	RU notebooks + LLM evaluation; 8 French datasets уже загружены в DeepPavlov
R&D качество	CLI, retries, cache, YAML configs, translation strategies, sanity checks
Масштабирование	новые датасеты добавляются через configs и стратегии, а не через ручную перепись pipeline
Публичность	GitHub repositories, Hugging Face datasets, README, project description, PDF deck

Публичные артефакты

French pipeline: github.com/lsachenkoBogdan/data-translate

Project description: [PROJECT_DESCRIPTION.md](#)

Russian track: github.com/interpparietes/DialogMTEB

French datasets: huggingface.co/DeepPavlov

MTEB: [Massive Text Embedding Benchmark](#)

Команды проверки и загрузки

```
make translate DATASET=faithdial  
make check-translation DATASET=faithdial  
make upload-datasets UPLOAD=daily_dialog_fr  
make upload-datasets-push UPLOAD=daily_dialog_fr
```

```
cd presentation  
npm run build  
npm run export
```

Основной invariant: source schema → translated artifact → sanity checks → parquet export → Hugging Face dataset repo.