

DialogMTEB

Многоязычное расширение диалогового embedding benchmark

25

диалоговых датасетов в общем
score

RU + FR

языковые треки практической
части

open-source

код, конфиги и публичные
артефакты

Кремнева Полина · Исаченко Богдан

Руководитель: Леднева Дарья

Почему это актуально

Где используются embeddings

- чат-боты и голосовые ассистенты
- поиск по диалогам поддержки
- retrieval-augmented dialogue systems
- классификация интенгов и маршрутизация обращений

Пробел в оценке

- общие benchmarks не всегда отражают диалоговую специфику
- в диалогах важны контекст, неполные реплики и прагматика
- многоязычное покрытие диалоговых задач остается ограниченным

Опора: MTEB как общий benchmark embeddings; DialogMTEB как диалоговое расширение задач оценки.

Исследовательская постановка

Можно ли расширить DialogMTEB на новые языки через автоматический перевод так, чтобы сохранить валидность benchmark-задач?

Гипотеза

Автоматический перевод + контроль качества позволяют получить пригодный многоязычный benchmark без ручной разметки каждого датасета с нуля.

Что должно сохраниться

- схема датасета и split semantics
- labels, ids, qrels, action syntax
- сопоставимость evaluation protocol
- воспроизводимость pipeline

Масштаб данных

Intent / classification

atis_intents · banking77 · vira-intent · CLINC150 ·
HWU64 · MTOPIntent · MASSIVE

Task-oriented dialogue

X-RiSAWOZ · Multi2WOZ · air-dialogue · FaithDial ·
DailyDialog

Conversational retrieval

statcan-dialogue-dataset-retrieval · WebLINX ·
CANARD · MANTIS · WoW · QReCC · TREC iKAT 2023 ·
Coral

QA / summarization

ClarQA · TopiOCQA · Abg-CoQA · DialogSum

Общий score команды: 25 датасетов разных типов диалоговых задач. В защите фокусируемся на том, как переводы делались воспроизводимо и проверяемо.

Команда и распределение задач

Участник	Участие	Зона ответственности	Что показывает на защите
Кремнева Полина	50%	русскоязычный трек, notebook-based перевод, Yandex Translator, LLM-as-a-judge	мотивация, русские переводы, LLM-оценка качества
Исаченко Богдан	50%	французский трек, CLI/pipeline, конфиги, validation, parquet export, загрузка в Hugging Face	pipeline, проверки, ошибки, артефакты и воспроизводимость

Руководитель: Леднева Дарья - постановка задачи, методологические консультации, рецензирование результатов.

Подход Полины: Russian track

Артефакты

- [interpparietes/DialogMTEB](#)
- `translator_yandex_*.ipynb`
- `LLM_Evaluation.ipynb`
- `DESCRIPTION.md` с описанием проекта

Ключевая идея

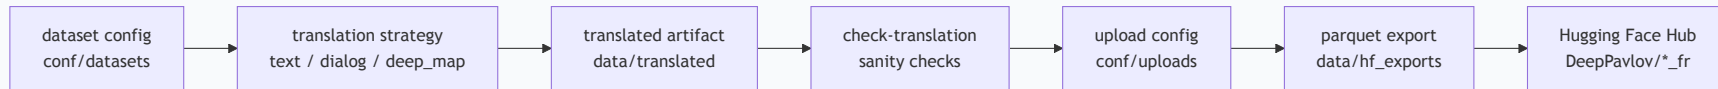
Для каждого датасета запускается перевод через Yandex Translator, затем LLM-as-a-judge оценивает качество перевода по нескольким критериям.

Accuracy & completeness

Grammar & orthography

Naturalness & style

Подход Богдана: французский pipeline



воспроизводимость
один CLI для разных
датасетов

учёт схемы
не ломаем labels, ids, qrels

готовность к загрузке
parquet layout для Hub

Контроль качества: что ловит pipeline

split / row count mismatch

пустые переводы

разные длины списков

непереведенный
английский текст

нарушение WebLINX action
sequence

misalignment строк на
DailyDialog

Чтобы не плодить ложные warnings, checker игнорирует технические строки: URLs, filenames, attachments, paths, emails, hash/id-like values.

Результаты и публичные артефакты

French dataset	Строк	Статус
<u>air_dialog_fr</u>	402037	загружен
<u>daily_dialog_fr</u>	102979	загружен
<u>canard_fr</u>	77250	загружен
<u>multiwoz_fr</u>	71410	загружен
<u>clarqa_fr</u>	34390	загружен
<u>weblinx_fr</u>	19657	загружен
<u>statcan_dialog_fr</u>	11358	загружен
<u>faithdial_fr</u>	3539	загружен*

Код: [IsachenkoBogdan/data-translate](#). В процессе: MANTIS, WoW, Abg-CoQA, Coral.

Ограничения и риски

Семантика

Автоматический перевод может менять стиль, терминологию и прагматику диалога.

Структура задачи

Labels, ids, URLs, qrels и action syntax часто нужно сохранять, а не переводить.

Неполные артефакты

FaithDial загружен с `history_fr` и `knowledge_fr`; `response/label` поля требуют отдельного решения.

Масштабирование

Сейчас

публичные RU/FR
артефакты, проверяемый
pipeline, первые HF uploads

Следующий этап

MANtIS, WoW, Abg-CoQA,
Coral; human audit; LLM
second-stage verification

Дальше

интеграция в multilingual
DialogMTEB evaluation и
расширение на другие
языки

Итог

Мы не просто перевели датасеты, а подготовили воспроизводимую основу для многоязычной оценки диалоговых embedding-моделей.

Научная ценность

многоязычная проверка
диалоговых embeddings

Инженерная ценность

pipeline, configs, checks,
upload automation

Публичность

GitHub repos и Hugging
Face datasets

Приложение

Проверка по критериям практики

Актуальность	диалоговые embeddings нужны для реальных ассистентов и поиска по разговорам
Практическая значимость	публичные multilingual datasets и воспроизводимые scripts/configs
Новизна	расширение DialogMTEB на RU/FR с контролем структуры задач
Impact	8 French datasets уже загружены; Russian track покрыт notebooks и LLM evaluation
R&D качество	CLI, tests, sanity checks, retries, configs, upload pipeline
Масштабирование	новые datasets добавляются через configs и translation strategies
Публичность	GitHub + Hugging Face Hub + оформленный README

Полезные ссылки

Французский pipeline: github.com/lsachenkoBogdan/data-translate

Русскоязычный трек: github.com/interpparietes/DialogMTEB

Французские датасеты: huggingface.co/DeepPavlov

MTEB: Massive Text Embedding Benchmark

DialogMTEB: dialogue-specific benchmark direction for embedding evaluation

Команды воспроизведения

```
make translate DATASET=faithdial  
make check-translation DATASET=faithdial  
make upload-datasets UPLOAD=daily_dialog_fr  
make upload-datasets-push UPLOAD=daily_dialog_fr
```

```
cd presentation  
npm run build  
npm run export
```

Основная проверка: source schema → translated artifact → sanity checks → parquet files → Hugging Face dataset repo.